

Python: atelier

LISTES et STRUCTURES ITÉRATIVES

Manipulation de listes représentant des textes

```
bovary_nltk.py ✕  iteratives.py ✕  bovary.txt ✕  
1 # pip install nltk  
2 import nltk  
3 #préparation  
4 #nltk.download("punkt") # Pour la ponctuation  
5 fichier = open("bovary.txt", encoding = "utf-8")  
6 bovary_string = fichier.read() # Python pure  
7 bovary_liste = nltk.word_tokenize(bovary_string)  
8 print(type(bovary_liste))  
9 bovary_texte = nltk.Text(bovary_liste)  
10 print(type(bovary_texte))  
11 bovary_phrase1 = bovary_liste[10:37]  
12 print(type(bovary_phrase1))  
13 print(bovary_phrase1)  
14 #Concordances  
15 print("Voici les concordances avec 'Emma' :")  
16 bovary_texte.concordance("Emma")  
17 #Similarités  
18 print("Combien de fois le mot 'beau' : ", bovary_texte.count("pauvre"))  
19 print("Voici les similarités avec le mot 'village' : ")  
20 bovary_texte.similar("village")  
21 #Génération de texte aléatoire  
22 print("Voici une génération de texte : ")  
23 bovary_texte.generate()  
24 #Diversité lexicale  
25 print("Diversité lexicale : ")  
26 print("Nombre de mots = ", len(bovary_liste))  
27 print("Taille du dictionnaire : ", len(set(bovary_liste)))  
28 print("Diversité lexicale = ", len(set(bovary_liste)) / len(bovary_liste))  
29 #Autres statistiques élémentaires  
30 print("Combien de fois le mot 'Rodolphe' : ", bovary_texte.count("Rodolphe"))  
31 print("La première apparition du mot 'Rodolphe' : ", bovary_texte.index("Rodolphe"))  
32 print("la proportion de 'le' dans le texte: ", 100 * bovary_texte.count("le") / len(bovary_texte))
```